

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
MATEMATINĖS INFORMATIKOS KATEDRA

**Monte Karlo metodai statistinių hipotezių
tikrinimui: Taikymai bioinformatikoje**
Motyvų radimas ir statistinio reikšmingumo vertinimas
Kursinio darbo projektas

Atliko: 3 kurso Bioinformatikos studentė
Meda Klapatauskaitė

Darbo vadovas: lekt. Irus Grinis

Vilnius 2026

TURINYS

IVADAS	2
1. TEORINIS KONTEKSTAS	3
1.1. DNR ir Genominės sekos	3
1.2. Sekos motyvai	3
1.3. Statistinių hipotezių tikrinimas	4
1.4. Monte Karlo Metodai	4
1.5. GC išsaugantis maišymas	5
1.6. Pirmos eilės Markov modelis	7
2. TYRIMO METODIKA	8
2.1. Duomenų rinkiniai	8
2.2. K-mer analizė ir motyvų identifikavimas	9
2.3. Nulinių modelių konstravimas	10
2.4. Monte Karlo simuliacijos ir statistinio reikšmingumo vertinimas	11
2.5. Motyvų lokalizacijos analizė	12
3. REZULTATAI	13
3.1. Monte Karlo pasiskirstymų konstravimas	13
3.2. Motyvų statistinio ir biologinio reikšmingumo vertinimas	15
3.3. Motyvo ilgio įtaka statistiniam reikšmingumui	16
4. DISKUSIJA	19
IŠVADOS	21
LITERATŪRA	22

Ivadas

Bioinformatikoje trumpų nukleotidų sekų, vadinamų motyvais, radimas yra vis dažnėjantis reikalavimas sparčiai augančioje genomų sekvenavimo pramonėje. Esant dideliems genomams, šie motyvai gali būti biologiškai reikšmingi ir siejami su tokiomis funkcijomis kaip genų reguliacija, replikacija, struktūrinė organizacija ar transkripcijos faktorių prisijungimas. Taipogi, dėl milžiniškos genomų apimties, motyviniai nukleotidų pasikartojimai gali susiformuoti visiškai atsitiktinai. Motyvų radimas dažnai atliekamas randant nukleotidų sekas, kurios kartotiniai pasitaiko dažniau nei atitinkamame palyginamojo genomo modelyje, tačiau motyvų dažnių interpretacija yra gan komplikuojama atsižvelgiant į tai, kad genominės sekos nėra visiškai atsitiktiniai nukleotidų kratiniai. Natūralūs genomi turi šališką nukleotidų kompoziciją, iš to seka, jog ne visiems motyvams galime priskirti biologinę prasmę. Dažnai pasikartojančios sekos atsitiktinumui patikrinti reikalingas statistinis metodas, kuriuo galima būtų apsiakičiuoti, ar rastas motyvas pastebėtas dažniau nei būtų tikimasi tinkamai apibrėžtoje NULL hipotezėje. Vienas tokių statistinių metodų, suteikiančių lankstų karkasą hipotezių testavimui atvejais, kai yra sudėtinga gauti statistinių tikimybių pasiskirstymą, yra Monte Karlo metodas. Šis siekia estimuoti bandymo statistiką remiantis dideliu kiekiu pakartotinių matavimų kurie generuojami remiantis nuline hipoteze.

Šiame darbe Monte Karlo hipotezių testavimas buvo pritaikytas motyvų radimui penkių organizmų genomuose. Pilnos genomų sekos buvo atsisiųstos iš National Center for Biotechnology Information (NCBI) genomų duomenų bazės ir išanalizuotos Python kalbos programomis. Dažni nukleotidų motyvai buvo identifikuoti k-merų skaičiavimu, tuomet kiekvienam genomui pritaikytas first-order Markov modelis siekiant išlaikyti lokalius nukleotidų santykius generuojant sintetines sekas. Daug sykių kartojamos Monte Karlo simuliacijos buvo naudotos nuspėti null motyvų dažnių pasiskirstymą, išvedamos empirinis p-reikšmės. Tikslas yra išanalizuoti, ar dažni genomuose identifikuoti motyvai pasitaiko dažniau, nei tikėtasi modelyje generuotam first-order Markov pagrindu. Bendrai ši analizė siekia pademonstruoti, kaip Monte Karlo metodai gali būti pritaikomi bioinformatikoje statistinių hipotezių tikrinimui ir įvertinti jų pritaikomumą motyvų reikšmingumo įvertinimui.

1. Teorinis kontekstas

1.1. DNR ir Genominės sekos

Deoksiribonukleorūgštis (DNR) - nukleorūgštis, organizmų pagrindinis genetinės informacijos vienetas. DNR sudaryta iš deoksiribonukleotidų. Deoksiribonukleotidas yra sudarytas iš heterociklinės azoto bazės ir angliavandenio deoksiribozės. Deoksinukleotidai skiriasi azoto bazėmis. Pagrindinės yra keturios: adeninas (A), guaninas (G), citozinas (C) ir timinas (T). Šių nukleotidų lemia ląstelių ir baltymų struktūrą, metabolizmą, organizmo augimą ir dauginimąsi. Pilna organizmo DNR seka yra vadinama Genomu.

Genomo sekas sudaro koduojantys ir nekoduojantys regionai. Koduojančius regionus sudaro genai, kurie yra transkribuojami ir transliuojami gaminant baltymus. Nekoduojančius regionus dažnai sudaro reguliatoriniai elementai ar struktūrinės sekos. Biologiškai reikšmingų šablonų radimas genomo sekoje yra dažnas ir svarbus bioinformatikos uždavinys.

1.2. Sekos motyvai

Sekos motyvas, tai genome atsikartojanti nukleotidų seka. Įvairūs motyvai gali būti siejami su biologiškai svarbiais elementais pvz.: transkripcijos faktoriais, struktūriniais, replikacijos, promotoriniais regionais [DD07]. Motyvų paieška siekia identifikuoti nukleotidų sekas, kurios genome atsikartoja dažniau, nei tikėtumėmės jas rasti atsitiktinai.

Dažna strategija motyvų atpažinimui yra k-mer analizė. K-meru vadiname k ilgio nukleotidų seką [JCB⁺25]. Pavyzdžiui: "ATGCGCTA" yra 8-meras. Radę ir suskaičiavę visus genome esančius k-merus, galime identifikuoti dažnai atsikartojančius motyvus ir tuomet testuoti jų statistinį reikšmingumą.

Žinodami vien motyvo kartojimosi dažnį mes bendrai negalime teigti, kad jis yra kažkaip biologiškai veiklus. Įvairiems genomams būdingos nukleotidų kompozicijos ir lokalizuotos sekų struktūros, kurios gali leisti motyvam dažniau kartotis, nesvarbu ar jiems būdingas biologinis veikumas. Todėl reikalingas statistinis testavimas siekiant nustatyti, ar pastebėtas motyvas yra tik šių šališkumų artifaktas.

1.3. Statistinių hipotezių tikrinimas

Statistinės hipotezės testavimas - strategija pritaikoma įvertinti stebėjimo rezultato atitikimą nulinei hipotezei. Motyvų analizės atveju nulinė hipotezė teigia, jog aptikto motyvo dažnis yra paaiškinamas vien sekos/modelio struktūra.

Pavyzdiniam motyvui M hipotezės gali būti formuojama taip:

H_0 : Motyvo M dažnis atitinka sekos modelio struktūrą.

H_1 : Motyvo M dažnis viršija sekos modelio struktūros dažnį.

Hipotezių testavimo tikslas yra nustatyti, ar motyvo dažnis yra pakankamai statistiškai negalimas nulinės hipotezės kontekste, kad pateisintų jos atmetimą. Tai tipiškai daroma apskaičiavus testo statistiką ir įvertinus tikimybę gauti tokį patį ar dar ekstremalesnį rezultatą nulinės hipotezės kontekste. Ši tikimybė išreikšta p -įverčiu.

Hipotezių testavimas turi platų pritaikymą bioinformatikos srityje (pvz.: genų ekspresyvumo analizė, sekų palyginimai, filogenetika, t.t...) Motyvų analizės atveju - siekiant įvertinti pasikartojimo atsitiktinumą. Jei apskaičiuotas p -įvertis yra mažesnis, nei parinktas reikšmės slenkstis (dažnai $p\text{-value} = 0.05$), NULL hipotezė yra atmetama. Atvejais, kai tikslią p -reikšmę sunku apskaičiuoti, galime naudoti simuliaciją grįstus metodus.

1.4. Monte Karlo Metodai

Monte Karlo metodai apima klasę skaičiavimo metodų, kurių veikimas grindžiamas atsitiktinių imčių generavimu ir pakartotinėmis statistinėmis simuliacijomis naudojamų aproksimuoti sudėtingus tikimybinius ir statistinius dydžius [LL01].. Šie metodai taikomi tais atvejais, kai dominančio statistinio parametro teorinis pasiskirstymas nėra žinomas arba jo analitinis išvedimas yra pernelyg sudėtingas. Vietoje tiesioginio matematinių išraiškų sprendimo, Monte Karlo metodai leidžia aproksimuoti ieškomus dydžius generuojant didelį kiekį atsitiktinių realizacijų ir analizuojant jų statistines savybes [KTB13].

Bendroji Monte Karlo metodų idėja yra pakeisti sudėtingą analitinį skaičiavimą daugybe pa-

prastų atsitiktinių eksperimentų. Kiekvieno eksperimento metu apskaičiuojama dominanti statistika, o pakankamai dideliu skaičiui gauti rezultatai konverguoja į tikrąją nagrinėjamo parametro reikšmę pagal didžiųjų skaičių dėsnį [KR12]. Dėl šios priežasties Monte Karlo metodai plačiai naudojami fizikoje, finansuose, statistikoje, mašininio mokymosi uždaviniuose ir bioinformatikoje.

Statistinių hipotezių tikrinime Monte Karlo metodai leidžia empiriškai sudaryti testinės statistikos pasiskirstymą pagal nulinę hipotezę. Tokie metodai ypač naudingi genominiuose tyrimuose, kuriuose analitiniai pasiskirstymai dažnai nėra žinomi arba yra sudėtingi apskaičiuoti [Lin05]. Vietoje teorinio pasiskirstymo išvedimo yra generuojama daug sintetinių duomenų rinkinių, kurie atitinka pasirinktą null modelį. Kiekvienam sugeneruotam duomenų rinkiniui apskaičiuojama dominanti statistika, o visų rezultatų visuma sudaro empirinį pasiskirstymą, su kuriuo gali būti lyginamas realiuose duomenyse stebėtas rezultatas [WB15].

Šio darbo tikslais Monte Karlo buvo naudojamas ištirti dažniausiai DNR aptinkamų motyvų statistinius reikšmingumus. Buvo sintetinami genomai, struktūriškai atitinkantys realųjį, kiekviename iš jų rasti motyvų kartojimosi dažniai. Daug kartų pakartojus šią procedūrą gauti empiriniai pasiskirstymai reprezentatyvūs gautiems motyvų pasikartojimams. Stebėto motyvo atsikartojimo reikšmingumas buvo kiekiškai naudojant empirinį p-įvertį:

$$p = \frac{r + 1}{N + 1},$$

Kur (N) - Monte Karlo simuliacijų skaičius, (r) - simuliacijos, kuriose motyvų atsikartojimų rasta tiek pat, arba daugiau, nei tikrajame genome. Toks p-reikšmės skaičiavimo būdas leidžia išvengti nulinių įverčių ir yra plačiai naudojamas Monte Karlo hipotezių testavimo procedūrose [KR12].

1.5. GC išsaugantis maišymas

Tinkamas nulinės hipotezės specifikacijos parinkimas yra kritiškai svarbus atliekant Monte Karlo hipotezių testavimą. Genomo sekų analizėje pradinė hipotezė lemia generuojamų duomenų charakteristikas - sprendžiama, kokios originalios sekos savybės išlaikomos simuliacijose ir kurios atitiks randomizuotą variaciją.

Paprasčiausias NULL hipotezės modelis daro prielaidą, jog visi nukleotidai nepriklausomi ir yra aptinkami tokiu pačiu dažniu, tačiau toks modelis neatitinka biologinės realybės. Vienas tikslesnis būdas sudaryti nulinį modelį sekos motyvų analizei yra atsitiktinai permaišyti genomo nukleotidus išlaikant bendrą nukleotidų kompoziciją. Toks metodas leidžia pašalinti lokalią sekos struktūrą, tačiau išsaugo bendras nukleotidų proporcijas genome.

Svarbi genomo charakteristika yra GC turinys (angl. *GC content*). GC turiniu vadinama guanino (G) ir citozino (C) nukleotidų dalis visoje sekoje. Jei genome yra N_G guanino ir N_C citozino nukleotidų, GC turinys apskaičiuojamas:

$$GC = \frac{N_G + N_C}{N}$$

kur N žymi bendrą nukleotidų skaičių genome.

Skirtingų organizmų genomuose GC turinys gali labai skirtis. Bakterijose stebima itin plati GC turinio variacija – nuo mažiau nei 20% iki daugiau nei 70% visų nukleotidų [HME10]. GC turinys daro tiesioginę įtaką tikėtinam nukleotidų motyvų dažniui. Genomuose, kuriuose gausu G ir C nukleotidų, GC turtingi motyvai pasitaikys dažniau net ir visiškai atsitiktinėje sekoje. Analogiškai, AT turtinguose genomuose dažniau aptinkami A ir T nukleotidų motyvai. Dėl šios priežasties vien stebimas motyvo pasikartojimo dažnis nėra pakankamas jo biologiniam reikšmingumui įvertinti. Motyvų statistiniam testavimui būtina naudoti palyginamuosius modelius, kurie išlaiko bent pagrindines realaus genomo savybes. Vienas paprasčiausių tokių modelių yra GC turinį išlaikantis atsitiktinės sekos modelis, kuriame sintetiniai genomai generuojami naudojant tas pačias nukleotidų proporcijas kaip ir realioje sekoje. Toks modelis leidžia įvertinti, kokio motyvų dažnio būtų galima tikėtis vien dėl bendros nukleotidų kompozicijos.

Šiame darbe GC turinį išlaikantis modelis buvo naudojamas kaip pradinis null modelis. Vėliau analizė buvo išplėsta taikant first-order Markov modelį, kuris išsaugo ne tik bendrą nukleotidų sudėtį, bet ir lokalius ryšius tarp gretimų nukleotidų.

1.6. Pirmos eilės Markov modelis

Siekiant Monte Karlo testavimą atlikti su dar tikslesniu pradiniu modeliu - galima atsižvelgti į realistišką genomo nukleotidų dažnį ir lokalizuotų sekų tendenciškumą - kai vieno nukleotido buvimas nurodo statistiškai reikšmingą tikimybę būti šale specifinio nukleotido.

Siekiant algoritmui suteikti padidintą biologinį tikslumą preliminarium GC-saugančiu randomizavimo modeliu gauti duomenys buvo patikrinti pirmos eilės (angl. *first-order*) Markov grįstu testavimo algoritmu. Pirmos eilės Markov procesas atsižvelgia į tikimybę aptikti nukleotidą pagal tiesiogiai prieš jį buvusį. Sekai $X_1, X_2, \dots, X_n, \dots, X_n$ šis sąryšis aprašomas kaip $P(X_i | X_{i-1})$.

Nukleotidų tikimybės estimuotos tiesiogiai suskaičiavus jų kiekius analizuojamame genome. Kiekvienam nukleotidui rasta moduliacijos tikimybė tuomet apskaičiuojant sąloginę to nukleotido tikimybę. To pasekoje gauname daug realistiškesnę sintetinio ghenomo stuktūrą, nei gautume su pilnai randomizuotu maišymu. Bendru atveju pirmos eilės Markov modelis yra priimtinas motyvų paieškai, nes jis atsižvelgia į aplinkinių nukleotidų poveikį motyvų atsiradimui [TAR07]. Šio darbo kontekste pirmos eilės Markov modelis bus naudojamas NULL hipotezės pagrindui. Kiekviena Monte Karlo simuliacija pradedama sugeneruojant sintetinius genomus remiantis estimuotomis moduliacijos (angl. *transition*) tikimybėmis. Motyvų džniai šiuose sintetiniuose genomuose tuomet palyginami su dažniais tikrajame genome, iš to gauname jų statistinį reikšmingumą.

2. Tyrimo metodika

Šio projekto programinį kodą galite rasti:

<https://github.com/SoiTrash/monte-carlo-motif-analysis>

2.1. Duomenų rinkiniai

Tyrimui buvo pasirinkti penki pilni genomai, atstovaujantys dvi skirtingas organizmų grupes – bakterijos ir grybai. Tokie organizmai buvo parinkti siekiant aprėpti platų genominio GC turinio spektrą bei įvertinti, kaip nukleotidų kompozicija įtakoja aptinkamų motyvų dažnius. Skirtingų bakterijų genomuose GC gali sudaryti nuo mažiau nei 20% iki daugiau nei 70% visų nukleotidų.[HME10; MC10].

Analizei buvo pasirinkti šie organizmai:

- **Mažo GC turinio bakterija**
 - *Mycoplasmoides genitalium*
- **Vidutinio GC turinio bakterijos**
 - *Escherichia coli* K-12
 - *Escherichia coli* O157:H7
- **Aukšto GC turinio bakterija**
 - *Streptomyces coelicolor*
- **Eukariotinis organizmas**
 - *Saccharomyces cerevisiae*

Pasirinkti organizmai pasižymi diferencijuota genomo organizacija. Į analizę buvo įtraukti tiek AT turtingi, tiek GC turtingi genomai, todėl galima įvertinti, kaip bazinė nukleotidų sudėtis veikia statistiškai reikšmingų motyvų atsiradimą.

Dviejų skirtingų *E. coli* atmainų (angl. *strain*) analizė buvo atlikta siekiant įvertinti, kiek motyvų pasiskirstymas gali skirtis tos pačios rūšies genomuose.

Genomo sekos buvo atsisiųstos iš National Center for Biotechnology Information (NCBI) genomų duomenų bazės FASTA formatu. Prieš atliekant analizę iš FASTA failų buvo pašalintos antraštės, visos sekos eilutės sujungtos į vientisą nukleotidų seką. Analizėje buvo naudojami tik keturi standartiniai nukleotidai: adeninas (A), timinas (T), guaninas (G) ir citozinas (C). Papildomi simboliai į analizę nebuvo įtraukti.

1 lentelė. Analizuotų genomų charakteristikos

Organizmas	Genomo ilgis (bp)	GC turinys (%)
<i>Mycoplasma genitalium</i>	580076	31.7
<i>E. coli</i> K-12	4641652	50.8
<i>E. coli</i> Sakai	5594605	50.5
<i>Streptomyces coelicolor</i>	8667664	72.1
<i>Saccharomyces cerevisiae</i>	12157105	38.1

Kiekvienam genomui buvo apskaičiuotas bendras sekos ilgis bei GC turinys. Šie parametrai buvo naudojami kaip pirminės genomo charakteristikos ir vėliau pritaikyti sudarant nulinius modelius. GC turinys buvo tiesiogiai naudojamas GC išsaugančio randomizavimo algoritmo konstravimui, o originalios sekos nukleotidų dažniai ir gretimų nukleotidų tikimybės buvo naudojamos pirmos eilės Markov modelio parametrų įvertinimui.

2.2. K-mer analizė ir motyvų identifikavimas

Pradinis motyvų identifikavimas buvo atliekamas naudojant k-mer analizę. Kiekvienoje genomo sekoje buvo peržiūrėtos visos galimos ilgio (k) nukleotidų sekos slenkančiu vieno nukleotido rėmu. Jeigu genomo ilgis yra (L), bendras nagrinėjamų k-merų skaičius apskaičiuojamas:

$$L - k + 1$$

Kiekvienam aptiktam k-merui buvo apskaičiuotas jo pasikartojimų skaičius genome. Vėliau visi k-merai buvo surikiuoti mažėjančia dažnio tvarka, tolimesnei statistinei analizei naudojami tik dažniausiai pasitaikę motyvai. Tokiu būdu Monte Karlo simuliacijos buvo taikomos

tik dažniausiems motyvams, o ne visiems genome aptiktiems k-merams.

Motyvo ilgio pasirinkimas turi reikšmingą įtaką tiek biologinei interpretacijai, tiek statistiniam vertinimui. Trumpi motyvai genomo kontekste gali būti aptinkami dažnai ir taip pat didesnė tikimybė atsitiktinai juos gauti simuliuojant. Kita vertus, ilgesni motyvai yra daug specifiškesni ir dažniau siejami su konkrečiomis biologinėmis funkcijomis, tačiau jų pasikartojimų skaičius genome sparčiai mažėja didėjant motyvo ilgiui.

Šiame darbe buvo analizuojami keli skirtingi motyvų ilgiai: 8, 10, 12 ir 15 nukleotidų. Toks pasirinkimas leido įvertinti, kaip motyvo ilgis veikia tiek jo biologinę interpretaciją, tiek statistinį reikšmingumą.

Trumpesni (pvz. 8-merai) motyvai yra plačiai paplitę genomo kontekste, todėl suteikia pakankamai statistinių duomenų dažnių palyginimui. Kita vertus yra didesnė tikimybė, jog jie aptinkami atsitiktinai, todėl gali būti sudėtinga juos interpretuoti biologiškai. Ilgesni (pvz. 12-15-merai) motyvai yra žymiai specifiškesni. Tačiau didėjant motyvo ilgiui jų pasikartojimų skaičius genome sparčiai mažėja, todėl analizė tampa jautresnė atsitiktiniams svyravimams. Pasirinkti motyvų ilgiai sudaro kompromisą tarp statistinio patikimumo ir biologinio specifiškumo.

Papildomai skirtingų k-mer ilgių analizė leido įvertinti, kaip pasirinktas motyvo ilgis veikia Monte Karlo simuliacijomis apskaičiuotą statistinį reikšmingumą. Buvo tikrinama hipotezė, kad didėjant motyvo ilgiui atsitiktinio pasikartojimo tikimybė mažėja greičiau nei stebimų motyvų dažnis realiuose genomuose.

2.3. Nulinių modelių konstravimas

Statistinio reikšmingumo vertinimas tiesiogiai priklauso nuo pasirinktos nulinės hipotezės. Motyvų analizės atveju nulinis modelis apibrėžia, kokio motyvų pasikartojimo dažnio būtų galima tikėtis genome nesant papildomų biologinių veiksnių. Kadangi realios genominės sekos pasižymi netolygia nukleotidų kompozicija ir lokaliomis struktūrinėmis priklausomybėmis, nulinio modelio pasirinkimas turi reikšmingą įtaką gautų rezultatų interpretacijai.

Pradiniame analizės etape buvo nagrinėjamas GC turinį išsaugantis atsitiktinės sekos mode-

lis. Šiame modelyje sintetiniai genomai generuojami išlaikant tas pačias nukleotidų proporcijas kaip ir tikrojoje sekoje. Toks metodas leidžia įvertinti, kokia motyvų dažnio dalis gali būti paaiškinama vien bendra nukleotidų kompozicija. Tačiau šis modelis daro prielaidą, jog visi nukleotidai yra statistiškai nepriklausomi vienas nuo kito ir neatsižvelgia į lokalias sekos struktūras. Dėl šios priežasties pagrindinei analizei buvo pasirinktas pirmos eilės Markov modelis, generuotos sekos sutapo ir realių genomų ilgiu.

Šiame darbe pateikiami statistinio reikšmingumo vertinimai ir Monte Karlo rezultatai buvo apskaičiuoti naudojant pirmos eilės Markov modelį.

2.4. Monte Karlo simuliacijos ir statistinio reikšmingumo vertinimas

Kiekvienos simuliacijos metu sugeneruotame genome buvo skaičiuojamas analizuojamo motyvo pasikartojimų skaičius. Ši procedūra buvo kartojama 1000 kartų kiekvienam motyvui. Remiantis gautais Monte Karlo pasiskirstymais dažniausiems motyvams buvo apskaičiuoti pagrindiniai statistiniai parametrai: pasiskirstymo vidurkis, standartinis nuokrypis ir 95% pasikliautinasis intervalas. Šie dydžiai leidžia įvertinti, kokio motyvų dažnio būtų galima tikėtis pagal pasirinktą nulinį modelį.

Papildomai buvo apskaičiuotas standartizuotas Z -įvertis:

$$Z = \frac{X - \mu}{\sigma},$$

kur X yra stebėtas motyvo pasikartojimų skaičius realiame genome, μ – Monte Karlo pasiskirstymo vidurkis, o σ – standartinis nuokrypis.

Teigiamos Z -įverčio reikšmės rodo, kad motyvas aptinkamas dažniau nei būtų tikėtina pagal nulinį modelį, o didelės teigiamos reikšmės leidžia įtarti statistiškai reikšmingą motyvo buvimą genome. Šiame darbe statistiškai reikšmingais buvo laikomi motyvai, kurių empirinė p -reikšmė buvo mažesnė nei 0.05.

2.5. Motyvų lokalizacijos analizė

Vien statistinis motyvo reikšmingumas neleidžia nustatyti jo biologinės funkcijos. Dėl šios priežasties pasirinktiems statistiškai reikšmingiems motyvams buvo atlikta papildoma lokalizacijos analizė.


Pirmiausia buvo nustatytos visos motyvo pozicijos genome. Toliau buvo apskaičiuoti atstumai tarp gretimų pasikartojimų. Ši analizė leido identifikuoti tandeminius pasikartojimus, pasikartojančius genominius regionus ir kitus struktūrinius elementus, kurie nėra tiesiogiai matomi vien iš motyvo dažnio statistikos. Kaikuriems motyvams atikta genomo anotacijos cross-validacija, tai leido rasti motyvų lokacijas susieti su realiai galimais genais, pseudo-genais.

3. Rezultatai

3.1. Monte Karlo pasiskirstymų konstravimas

Pirmasis tyrimo etapas buvo skirtas empiriškai sudaryti motyvų pasikartojimų pasiskirstymus pagal nulinę hipotezę. Kiekvienam analizuojamam genomui buvo apskaičiuotas pirmos eilės Markov modelis, iš kurio vėliau generuota po 1000 sintetinių genomų. Kiekvienoje simuliacijoje buvo skaičiuojamas pasirinkto motyvo pasikartojimų skaičius, o gautos reikšmės naudotos sudarant Monte Karlo pasiskirstymą.

Pateikti penkių organizmų reprezentatyvių 10-mer motyvų Monte Karlo pasiskirstymai. Histogramose parodytas tikėtinas motyvų dažnių pasiskirstymas pagal pirmos eilės Markov modelį bei stebėtas motyvo pasikartojimų skaičius realiame genome.



1 pav. 1 pav. pateikti penkių analizuotų genomų dažniausių 10-mer motyvų Monte Karlo pasiskirstymai. Visais atvejais stebėti motyvų dažniai viršijo pagal pirmos eilės Markov modelį tikėtinas reikšmes. Ryškiausi nukrypimai nustatyti *S. cerevisiae* ir abiejose *E. coli* padermėse, tuo tarpu *M. genitalium* genome stebėtas skirtumas buvo santykinai mažesnis.

Visais analizuotais atvejais stebėti motyvų dažniai buvo didesni nei vidutinės Monte Karlo pasiskirstymų reikšmės. Ryškiausi skirtumai matosi abiejų *Escherichia coli* padermių ir *Saccharomyces cerevisiae* genomuose, kuriuose dažniausių motyvų pasikartojimų skaičius viršijo pirmos eilės Markov modelio prognozes net iki keliolikos kartų. Tuo tarpu *Mycoplasma genitalium* genome skirtumas tarp stebėtų ir modeliu prognozuotų dažnių buvo gerokai mažesnis.

Gauti rezultatai patvirtina, kad Monte Karlo metodas leidžia praktiškai aproksimuoti sudėtingų sekos statistinių charakteristikų pasiskirstymus ir sudaro pagrindą tolimesniam statistinio

reikšmingumo vertinimui.

3.2. Motyvų statistinio ir biologinio reikšmingumo vertinimas

Monte Karlo simuliacijų rezultatai parodė, kad keliuose analizuotuose genomuose aptikti motyvai pasitaiko reikšmingai dažniau, nei būtų tikėtina pagal pirmos eilės Markov modelį. Toks rezultatas leidžia atmesti nulinę hipotezę, jog šių motyvų dažnis yra vien bendros nukleotidų kompozicijos ir lokalių sekos priklausomybių pasekmė.

2 lentelė. Dažniausių 10-mer motyvų statistinis reikšmingumas pagal Monte Karlo simuliacijas

Organizmas	Motyvas	Stebėta	MC vidurkis	95% PI	Z	p
<i>E. coli</i> K12	CGCATCCGGC	150	10.1	[5, 17]	44.2	< 0.001
<i>E. coli</i> Sakai	CAGCGCCAGC	158	10.3	[4, 17]	45.8	< 0.001
<i>M. genitalium</i>	TTTTTTAAAA	67	47.0	[34, 62]	2.8	0.0050
<i>S. coelicolor</i>	GCCGCCGCCG	1030	288.7	[254, 327]	40.2	< 0.001
<i>S. cerevisiae</i>	AAAAAAAAAAAA	4194	302.5	[253, 353]	153.9	< 0.001

Lentelėje 2 pateikti dažniausių kiekvieno organizmo 10-mer motyvų statistinio reikšmingumo rezultatai. Visuose tirtuose genomuose stebėti motyvų dažniai viršijo pirmos eilės Markov modelio prognozes.

Keturiuose iš penkių analizuotų genomų nustatyti itin dideli nukrypimai nuo nulinio modelio. Abiejų *Escherichia coli* bei *Streptomyces coelicolor* genomuose stebėti motyvų dažniai dešimtis kartų viršijo Monte Karlo simuliacijų vidurkius. Tai atsispindi itin didelėse Z įverčių reikšmėse, siekiančiose nuo 40 iki 46. Dar ryškesnis rezultatas gautas *Saccharomyces cerevisiae* genome, kuriame motyvo „AAAAAAAAAAAA“ stebėtas dažnis daugiau nei trylika kartų viršijo modelio prognozę, o apskaičiuotas Z įvertis siekė net 153.9. Visais šiais atvejais gautos p reikšmės buvo mažesnės nei 0.001, todėl nulinė hipotezė buvo atmesta.

Išsiskyrė *Mycoplasma genitalium* genomai. Nors motyvas „TTTTTTAAAA“ taip pat buvo aptiktas dažniau nei prognozavo nulinis modelis, skirtumas buvo gerokai mažesnis.

Apskaičiuotas Z įvertis siekė 2.8, o empirinė p reikšmė buvo lygi 0.005. Tai rodo, kad motyvas išlieka statistiškai reikšmingas, tačiau jo praturtėjimas yra žymiai silpnesnis nei kituose tirtuose genomuose gali būti susiję ypač nedideliu organizmo genomu. Kadangi trumpesniame genome bendras galimų k-mer pasikartojimų skaičius yra mažesnis, tiek stebėti, tiek Monte Karlo simuliacijose generuojami motyvų dažniai pasižymi mažesniu absoliučiu skirtumu. Dėl to statistiškai reikšmingi nukrypimai nuo nulinio modelio tampa sunkiau aptinkami nei didesniuose genomuose.

Atlikus papildomą lokacijos ir biologinės funkcijos analizę (specifiškai *Saccharomyces cerevisiae* 10-mer "AAAAAAAAAA") stebėtam motyvui, siekiant nustatyti ar statistiškai reikšmingi motyvai gali būti susiję su konkrečiomis biologinėmis funkcijomis, jis buvo aptiktas netoli anotacijose aprašytų genų, pseudogenų bei pasikartojančiuose genominiuose regionuose. Tokie rezultatai leidžia manyti, kad bent dalis aptiktų motyvų galėtų būti susiję su specifinėmis genomo struktūromis arba funkciniais elementais. Reikėtų atlikti išsamesnę biologinę analizę.

Šie rezultatai pabrėžia vieną svarbiausių Monte Karlo hipotezių testavimo privalumų bioinformatikoje. Statistinis reikšmingumas savaime neleidžia nustatyti biologinės funkcijos, tačiau leidžia išskirti motyvus, kurie pasitaiko dažniau nei būtų tikėtina pagal pasirinktą nulį modelį. Tolimesnė tokių motyvų analizė gali padėti identifikuoti potencialiai funkcinis genomų elementus ir nukreipti detalesnius biologinius tyrimus.


3.3. Motyvo ilgio įtaka statistiniam reikšmingumui

Pastebėta, kad didėjant motyvo ilgiui stebimų pasikartojimų skaičius genome mažėja. Tai yra tikėtinas rezultatas, nes ilgesnės nukleotidų sekos turi mažesnę tikimybę atsirasti atsitiktinai. Dėl šios priežasties ilgesni motyvai dažnai pasižymėjo didesniais nukrypimais nuo Monte Karlo pasiskirstymų vidurkių ir didesniais Z-įverčiais. Kitaip tariant, nors ilgesni motyvai genome aptinkami rečiau, jų pasikartojimai dažnai yra daug sunkiau paaiškinami atsitiktinėmis sekos savybėmis.

Šis rezultatas atitinka biologinius lūkesčius. Trumpi motyvai dažnai atspindi bendras geno-

mo kompozicines tendencijas, tuo tarpu ilgesni motyvai yra specifiškesni ir dažniau siejami su pasikartojančiomis genomo struktūromis, reguliaciniais elementais arba konservatyviais regionais.

Siekiant palyginti skirtingų organizmų rezultatus, buvo apskaičiuotas stebėto ir pagal Markov modelį tikėtino motyvo dažnio santykis. Kadangi kai kuriems ilgesniems motyvams tikėtinas dažnis buvo labai mažas arba artimas nuliui, rezultatų vizualizacijai naudota logaritminė transformacija:



2 pav. Motyvo ilgio įtaka statistiniam praturtėjimui skirtinguose genomuose. Pateikta logaritminė stebėto ir pagal pirmos eilės Markov modelį tikėtino motyvo dažnio santykio reikšmė skirtingų ilgių motyvams. Didėjanti kreivė rodo, kad ilgesni motyvai tampa vis sunkiau paaiškinami pasirinktu nuliniu modeliu.

Kaip matyti iš grafiko, daugumoje organizmų statistinis motyvų praturtėjimas didėjo ilgėjant motyvui. Ryškiausias efektas nustatytas *S. cerevisiae* genome, kuriame 15-mer motyvai demonstravo didžiausią praturtėjimą lyginant su Monte Karlo nuliniu modeliu. Tuo tarpu abi *E. coli* atmainos pasižymėjo labai panašiomis kreivių formomis, toks rezultatas rodo, jog aptiktos tendencijos yra pakankamai stabilios ir nėra vien konkretaus genomo artefaktas.

Streptomyces coelicolor genome stebėta kiek kitokia tendencija. Trumpesnių motyvų (8–12 nukleotidų) statistinis praturtėjimas buvo santykinai nedidelis ir augo lėtai. Toks rezultatas

gali būti siejamas su itin aukštu šio organizmo GC turiniu, kuris viršija 70%. Dėl didelės G ir C nukleotidų gausos daugelis dažniausiai aptinkamų GC turtingų motyvų gali būti pakankamai gerai paaiškinami vien nukleotidų kompozicija ir lokaliomis sekos priklausomybėmis. Vis dėlto 15-mer motyvų analizė parodė ryškų statistinio praturtėjimo padidėjimą. Tai rodo, kad ilgesnių motyvų pasikartojimų dažnis nebegali būti paaiškinamas vien bendru GC turiniu ar pirmos eilės Markov modelio aprašomomis priklausomybėmis.

Kitokia situacija stebėta *Mycoplasma genitalium* genome. Trumpesnių motyvų statistinis signalas buvo palyginti silpnas, tačiau tarp 10-mer ir 12-mer motyvų stebėtas ryškus statistinio praturtėjimo šuolis. Toks rezultatas gali būti susijęs su itin mažu šio organizmo genomu bei žemu GC turiniu.

Gauti rezultatai rodo, kad motyvo ilgio pasirinkimas turi tiesioginę įtaką statistinio hipotezių testavimo rezultatams. Todėl praktiniuose bioinformatikos taikymuose svarbu pasirinkti tokį motyvo ilgį, kuris užtikrintų kompromisą tarp pakankamo stebėjimų skaičiaus ir biologinio specifiškumo.

4. Diskusija

Šio darbo rezultatai parodė, kad Monte Karlo metodai gali būti efektyviai taikomi sekų motyvų statistiniam reikšmingumui vertinti bioinformatikos uždaviniuose. Pirmos eilės Markov modeliu pagrįstos simuliacijos leido sėkmingai aproksimuoti motyvų pasikartojimų pasiskirstymus. Visuose analizuotuose genomuose bent dalis dažniausių motyvų pasitaikė dažniau, nei būtų tikėtina pagal pasirinktą nulį modelį. Ypač ryškios tendencijos pastebėtos *Saccharomyces cerevisiae* bei *Escherichia coli* genomuose. Analizuojant skirtingų ilgių motyvus nustatyta, kad statistinis signalas daugeliu atvejų stiprėjo ilgėjant motyvui.

Svarbu pažymėti, kad šiame darbe buvo nagrinėti du skirtingi nulinių modelių konstravimo principai. Pradiniame etape buvo išbandytas GC turinį išsaugantis atsitiktinės sekos modelis, tačiau galutinėje analizėje pasirinktas pirmos eilės Markov modelis. GC turinį išsaugantis modelis leidžia kontroliuoti bendrą nukleotidų kompoziciją, tačiau neatsižvelgia į lokalias priklausomybes tarp gretimų nukleotidų. Dėl šios priežasties jis gali pervertinti kai kurių motyvų statistinį reikšmingumą. Pirmos eilės Markov modelis išsaugo tiek nukleotidų dažnius, tiek gretimų nukleotidų sąlygines tikimybes, todėl laikomas biologiniu požiūriu realistiškesniu nuliniu modeliu.

Papildomai svarbu pažymėti, kad statistinis reikšmingumas savaime neįrodo biologinės funkcijos. Nors atlikta preliminarinė motyvų lokalizacijos analizė parodė, kad kai kurie motyvai aptinkami šalia anotacijose aprašytų genų ar pasikartojančių regionų, funkciniam jų vaidmeniui nustatyti reikalingi papildomi biologiniai tyrimai. Todėl šiame darbe gauti rezultatai turėtų būti vertinami kaip potencialių biologiškai svarbių motyvų identifikavimo etapas.

Vienas pagrindinių darbo apribojimų yra pasirinktas nulinis modelis. Nors pirmos eilės Markov modelis išsaugo lokalias nukleotidų priklausomybes ir yra gerokai realistiškesnis už paprastą nukleotidų maišymą, jis vis dar neaprašo aukštesnės eilės sekų struktūrų, pasikartojančių elementų ir tolimesnių genominių priklausomybių. Ateityje analizę būtų galima išplėsti taikant antros ar trečios eilės Markov modelius bei lyginant jų rezultatus su šiame darbe gautais įverčiais.

Dar viena galima tyrimo kryptis būtų išplėsti analizuojamų organizmų spektrą. Įtraukus dau-

giau bakterijų, archėjų, grybų, augalų ar gyvūnų genomų būtų galima sistemingiau įvertinti, kaip motyvų statistinis reikšmingumas priklauso nuo geno dydžio, GC turinio bei evoliucinės kilmės.

Išvados

1. Buvo sukurta Monte Karlo simuliacijomis pagrįsta metodika DNR sekų motyvų statistiniam reikšmingumui vertinti naudojant pirmos eilės Markov modelį kaip nulio hipotezės pagrindą.
2. Monte Karlo metodas leido empiriškai sudaryti motyvų pasikartojimų pasiskirstymus ir apskaičiuoti jų statistinį reikšmingumą net tais atvejais, kai teorinis pasiskirstymas nėra lengvai išvedamas analitiškai.
3. Visuose analizuotuose genomuose buvo aptikti motyvai, kurių pasikartojimų dažnis reikšmingai viršijo pirmos eilės Markov modelio prognozes, todėl nulinė hipotezė buvo atmesta.
4. Nustatyta, kad motyvo ilgis turi reikšmingą įtaką statistinio hipotezių testavimo rezultatams. Daugeliu atvejų ilgesni motyvai demonstravo stipresnį nukrypimą nuo nulio modelio nei trumpesni motyvai.
5. Gauti rezultatai parodė, kad Monte Karlo metodai yra tinkama priemonė bioinformatikos uždaviniuose, susijusiuose su sekų motyvų paieška ir statistiniu reikšmingumo vertinimu.

Literatūra

- [DD07] Modan K Das ir Ho-Kwok Dai. A survey of DNA motif finding algorithms. *BMC bioinformatics*, 8(Suppl 7):S21, 2007.
- [HME10] Falk Hildebrand, Axel Meyer ir Adam Eyre-Walker. Evidence of selection upon genomic GC-content in bacteria. *PLoS genetics*, 6(9):e1001107, 2010.
- [JCB⁺25] Katharine M Jenike, Lucía Campos-Domínguez, Marilou Boddé, José Cerca, Christina N Hodson, Michael C Schatz ir Kamil S Jaron. K-mer approaches for biodiversity genomics. *Genome research*, 35(2):219, 2025.
- [KR12] Dirk P Kroese ir Reuven Y Rubinstein. Monte carlo methods. *Wiley Interdisciplinary Reviews: Computational Statistics*, 4(1):48–58, 2012.
- [KTB13] Dirk P Kroese, Thomas Taimre ir Zdravko I Botev. *Handbook of monte carlo methods*. John Wiley & Sons, 2013.
- [Lin05] DY Lin. An efficient Monte Carlo approach to assessing statistical significance in genomic studies. *Bioinformatics*, 21(6):781–787, 2005.
- [LL01] Jun S Liu ir Jun S Liu. *Monte Carlo strategies in scientific computing*, tom. 10. Springer, 2001.
- [MC10] Scott Mann ir Yi-Ping Phoebe Chen. Bacterial genomic G+C composition-eliciting environmental adaptation. *Genomics*, 95(1):7–15, 2010. ISSN: 0888-7543. DOI: <https://doi.org/10.1016/j.ygeno.2009.09.002>. URL: <https://www.sciencedirect.com/science/article/pii/S0888754309002080>.
- [TAR07] Vivek Thakur, Rajeev K Azad ir Ram Ramaswamy. Markov models of genome segmentation. *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, 75(1):011915, 2007.
- [WB15] J-C Walter ir Gerard T Barkema. An introduction to Monte Carlo methods. *Physica A: Statistical Mechanics and its Applications*, 418:78–87, 2015.